

Reprodutibilidade Científica em ESG: Reexecução de um Pipeline de Aprendizado de Máquina no Setor Têxtil

Luiz Sergio Pompeu Alves Filho
luizsergio.filho@copin.ufcg.edu.br
Universidade Federal de Campina Grande
Campina Grande, Paraíba, Brasil

José Antão Beltrão Moura
antao@computacao.ufcg.edu.br
Universidade Federal de Campina Grande
Campina Grande, Paraíba, Brasil

Abstract

O aumento das demandas por sustentabilidade na indústria têxtil global impulsionou a divulgação de relatórios Ambientais, Sociais e de Governança (ESG). Para viabilizar o monitoramento automatizado desses documentos, Magotra et al. [5] propuseram um pipeline de Processamento de Linguagem Natural (PLN) e aprendizado de máquina focado em empresas têxteis com certificação LEED em Bangladesh. Este trabalho apresenta uma reprodução computacional parcial desse ecossistema técnico para avaliar de forma rigorosa sua estabilidade, consistência e reprodutibilidade. A reexecução experimental utilizou o corpus secundário original contendo dados textuais de 82 corporações. Os achados validam com precisão decimal as propriedades estatísticas da pesquisa de referência: o algoritmo de Fatoração de Matrizes Não-Negativas (NMF) demonstrou superioridade algébrica frente à Alocação Latente de Dirichlet (LDA), eliminando sobreposições redundantes e isolando quatro macrotemas com distâncias de cosseno limitadas a 1,0. Adicionalmente, o classificador Random Forest, acoplado a embeddings Word2Vec, alcançou acurácia média de 87,16% e F1-score ponderado de 86,92% sob validação cruzada ($k = 5$). Por fim, a modelagem topológica de grafos via NetworkX ratificou as estruturas discursivas originais, revelando núcleos semânticos coesos voltados à segurança contra incêndios e investimentos locais em saúde pediátrica. Conclui-se que o framework auditado exibe alta maturidade e resiliência, qualificando-se como uma arquitetura confiável para auditoria socioambiental automatizada em cadeias de suprimentos complexas.

Keywords

Processamento de Linguagem Natural, Aprendizado de Máquina, Modelagem de Tópicos, Relatórios ESG, Indústria Têxtil.

1 Introdução

Diante do crescimento da pressão sob as empresas têxteis e de aparatos para que as mesmas assumam posturas sustentáveis, uma vez que as mesmas são famigeradas pelo seu impacto ecológico negativo e condições precárias de trabalho ao longo de décadas de suas histórias (a exemplo do gasto e contaminação de água [6] e desastres sociais como o desabamento do edifício Rana Plaza que ocasionou a morte de mais de mil pessoas e deixou mais de duas mil e quinhentas gravemente feridas [3]), as divulgações de métricas Ambientais, Sociais e de Governança (ESG) se tornaram um componente central da responsabilidade corporativa.

Em países como Bangladesh, que atua como um dos maiores exportadores globais de vestuário [4], a integração de práticas ESG transparentes tornou-se crucial não apenas para mitigar riscos e melhorar as condições de trabalho, mas também para manter a

competitividade internacional. Entretanto, o aumento do volume de relatórios de sustentabilidade ocasionado por tal mudança na postura empresarial acaba por tornar a atividade de análise de tais documentos algo desafiador. Nesse contexto, Magotra et al. (2026) [5] propuseram um pipeline de aprendizado de máquina para extrair, categorizar e analisar as práticas ESG em fábricas de vestuário e têxteis em Bangladesh com certificação LEED (Leadership in Energy and Environmental Design).

Utilizando técnicas de Fatoração de Matrizes Não-Negativas (NMF) [2] para modelagem de tópicos e um classificador Random Forest, os autores analisaram o conteúdo dos sites de 82 empresas. O estudo original identificou quatro temas dominantes: Sustentabilidade Ambiental, Segurança no Local de Trabalho (Social I), Educação e Programas Comunitários (Social II), e Governança, os quais foram analisados a fim de identificar o quão representados nos relatórios cada um dos temas eram, além de observarem descritivamente que níveis mais altos de certificação LEED pareciam estar correlacionados com práticas ESG mais equilibradas.

A fim de verificar a estabilidade do pipeline de PLN proposto e a consistência dos temas ESG no setor têxtil, esta pesquisa conduz uma reprodução do trabalho de Magotra et al. [5]. Especificamente, este trabalho objetiva: reproduzir a extração de tópicos e a classificação utilizando o mesmo arcabouço metodológico de NMF e Random Forest e validar os valores obtidos a partir da análise dos relatórios ESG da indústria têxtil e de vestuário. Ao fazer isso, este estudo busca fortalecer a literatura sobre auditoria automatizada de ESG e fornecer evidências mais robustas sobre a aplicabilidade de algoritmos de aprendizado de máquina na formulação de políticas de sustentabilidade corporativa.

2 Metodologia

Esta seção apresenta o planejamento detalhado do experimento de reprodução computacional, descrevendo formalmente as questões de pesquisa que guiam o estudo, o desenho do experimento com suas respectivas variáveis, a procedência dos dados e o ecossistema de ferramentas selecionado para a execução.

2.1 Questões de pesquisa

Para avaliar de forma rigorosa a estabilidade, consistência e reprodutibilidade do framework proposto por Magotra et al. [5], este estudo busca responder empiricamente a três Questões de Pesquisa:

- A execução direta do pipeline de Processamento de Linguagem Natural baseado em Fatoração de Matrizes Não-Negativas (NMF) reproduz com exatidão a extração dos 4 macro temas ESG e sustenta os índices de coerência semântica reportados no estudo original?

- O modelo classificador supervisionado baseado em Random Forest reproduz de forma idêntica a capacidade preditiva descrita na pesquisa de referência, atingindo a acurácia global de 87,2% e o F1-score de 0,86 sobre os dados das empresas têxteis?
- As métricas de centralidade estrutural obtidas por meio dos grafos de coocorrência de termos validam de forma consistente a dominância dos tópicos de Sustentabilidade Ambiental e Segurança Ocupacional descritos originalmente?

2.2 Desenho do experimento

O estudo classifica-se como um experimento de reprodução computacional parcial, cujo arranjo experimental foi desenhado para auditar a estabilidade e a corretude do pipeline original sob as mesmas condições computacionais estabelecidas pelos autores de referência. Como variáveis independentes, o experimento fixa a configuração algorítmica e os hiperparâmetros originais fornecidos nos scripts, mapeando a inicialização pelo método *Non-Negative Double Singular Value Decomposition* (NNDSDV) [1] no algoritmo NMF (n-components = 4) e o estado de aleatoriedade controlado (random_state=42) no classificador Random Forest.

Por outro lado, as variáveis dependentes correspondem aos outputs estatísticos gerados pelas execuções, os quais serão medidos quantitativamente e confrontados diretamente com os dados publicados. A consistência da modelagem de tópicos será mensurada por meio do cálculo de coerência semântica via modelo de avaliação e da distância de cosseno inter-tópicos extraída das distribuições matriciais. O desempenho do classificador supervisionado será avaliado através da extração das métricas de acurácia global e F1-score ponderado, gerados a partir do relatório de classificação gerado sobre a partição de teste estabelecida no pipeline de aprendizagem de máquina.

2.3 Obtenção dos dados

Para mitigar eventuais vieses de coleta externa, o experimento baseia-se integralmente na utilização de dados secundários pré-existent obtidos de maneira aberta no repositório público dos autores originais, alinhando-se com as práticas de ciência aberta. O corpus textual é composto pelas informações brutas fornecidas pelos autores do trabalho reproduzido, as quais foram extraídas das seções institucionais de 82 empresas têxteis e de vestuário de Bangladesh que possuem a certificação LEED. Como insumo complementar para o processo de classificação supervisionada, o estudo utiliza o conjunto estruturado de palavras-chave associadas às práticas ESG, o qual foi previamente validado por profissionais da área durante a pesquisa de referência. Cabe ressaltar que não existem restrições de acesso ou de direitos autorais que impeçam o uso ou comprometam a reprodutibilidade integral desta base de dados.

2.4 Ferramentas e Ambiente de Execução

Com o intuito de garantir que o experimento seja perfeitamente reproduzível por terceiros, todo o ambiente tecnológico foi planejado utilizando a linguagem de programação Python e seu ecossistema de bibliotecas especializadas. A manipulação e a estruturação inicial do corpus em data frames serão realizadas com a biblioteca

pandas, aplicando-se expressões regulares (Regex) para a limpeza de caracteres especiais. As etapas subsequentes de Processamento de Linguagem Natural contarão com a biblioteca Gensim para tokenização, remoção de stop-words e extração de trigramas, enquanto a lematização seletiva baseada em classes gramaticais (POS-tagging) será executada com o auxílio da biblioteca SpaCy. Para o cálculo dos pesos TF-IDF, além do treinamento e validação dos modelos de tópicos e classificadores lineares e baseados em árvores, será empregada a biblioteca Scikit-learn. A vetorização densa que alimenta os classificadores usará embeddings pré-treinados do Word2Vec. Por fim, a modelagem computacional dos grafos não-direcionados e o cálculo das métricas de centralidade serão feitos via NetworkX, com suporte gráfico para matrizes de confusão e mapas de distância. Todo o pipeline será concentrado em ambiente de notebooks interativos (Google Colab), facilitando a exportação e auditoria futura dos artefatos produzidos.

3 Resultados e discussão

Esta seção expõe os achados empíricos obtidos a partir da reexecução computacional do pipeline de Processamento de Linguagem Natural e Aprendizagem de Máquina, analisando a capacidade de reprodução dos dados originais.

3.1 Apresentação e Interpretação dos Dados de Modelagem de Tópicos (NMF)

A fim de verificar a estabilidade semântica do pipeline e validar a escolha algorítmica de Magotra et al. [5], a reexecução experimental realizou uma análise comparativa direta entre o modelo original baseado em Fatoração de Matrizes Não-Negativas (NMF) e a abordagem probabilística tradicional por Alocação Latente de Dirichlet (LDA). Utilizando a biblioteca Scikit-Learn, foi estruturado um vetorizador de contagem de palavras (CountVectorizer), parametrizado com um teto de frequência documental (max_df) de 95% e corte mínimo (min_df) de ocorrência em dois documentos. Sob uma semente de aleatoriedade controlada (random_state=0), o algoritmo LDA mapeou a distribuição latente do *corpus* em quatro macrotemas, cujos termos dominantes recuperados encontram-se sumarizados na Tabela 1.

Table 1: Termos Dominantes Extraídos e Dimensões ESG Atribuídas via LDA

Identificador	Termos Mais Frequentes (Top 10 Words)
Tópico 1	worker, employee, provide, work, health, facility, environment, people, child, community
Tópico 2	program, school, foundation, worker, provide, energy, student, water, free, donate
Tópico 3	worker, company, management, water, work, business, environmental, factory, sustainability, staff
Tópico 4	water, worker, safety, facility, fire, group, system, environment, employee, environmental

A inspeção qualitativa da Tabela 1 revela uma fragilidade latente no comportamento probabilístico do LDA para este domínio específico. Nota-se uma acentuada sobreposição de termos estruturais e repetitivos em múltiplos tópicos, onde a palavra-chave *worker* atua como elemento dominante em todos os quatro eixos extraídos, enquanto os termos *water*, *environment* e *employee* permeiam de forma redundante três das quatro divisões. Esse fenômeno indica uma baixa separação geométrica, uma vez que o algoritmo falhou em isolar de forma estrita as fronteiras conceituais entre os pilares Ambiental, Social e de Governança. No Tópico 3, por exemplo, ocorre um amálgama discursivo entre termos essencialmente administrativos corporativos (*company*, *management*, *business*) e vocábulos operacionais de chão de fábrica (*factory*, *staff*, *water*), reduzindo a capacidade de auditoria automatizada e a interpretabilidade humana do modelo. C Para quantificar essa limitação, o pipeline foi espelhado no ecossistema Gensim através da classe “LdaModel”, gerando representações baseadas em sacos de palavras (*bag-of-words*) indexadas por dicionário estruturado. A avaliação da qualidade intrínseca do modelo via métrica de coerência semântica retornou um *Coherence Score* (C_v) de 0,3, o que condiz com os resultados apresentados pelo estudo original.

Em contrapartida, a aplicação do algoritmo NMF com inicialização controlada por Decomposição em Valores Singulares Duplos Não-Negativos (NNDSVD) e semente de aleatoriedade fixa (*random_state=42*) extraiu quatro macrotemas com alto grau de especialização e sem sobreposição de vocabulário, tendo um *Coherence Score* (C_v) de 0,3756. A Tabela 2 sumariza a distribuição de pesos para os termos dominantes obtidos a partir da matriz de recursos TF-IDF.

Table 2: Termos Dominantes Extraídos e Dimensões ESG Atribuídas via NMF

Identificador	Termos Mais Frequentes (Top 10 Words)
Tópico 1	worker, safety, fire, facility, employee, maintain, provide, compliance, factory, medical
Tópico 2	sustainability, water, environmental, business, reduce, environment, energy, waste, product, sustainable
Tópico 3	program, worker, school, provide, health, education, support, student, child, free
Tópico 4	art, pediatric, burn, appointment, unit, people, intensive, state, competition, care

O exame da Tabela 2 evidencia a superioridade algébrica do NMF em segmentar o discurso corporativo. O Tópico 1 captura de forma estrita as obrigações regulatórias de segurança física e infraestrutura industrial, refletindo as reformas estruturais históricas sofridas pelo setor de vestuário em Bangladesh. O Tópico 2 agrupa a gestão de ecoeficiência operacional, enquanto o Tópico 3 delineia programas de responsabilidade social externa voltados à educação e suporte a vulneráveis. Por fim, o Tópico 4 revela uma assinatura bastante específica do corpus, concentrando termos associados a investimentos institucionais em unidades médicas e de saúde infantil.

Para ratificar a independência matemática desses componentes, calculou-se a matriz de distância pareada de cosseno sobre os vetores de tópicos do NMF (W), expressa visualmente no mapa de calor gerado na saída do pipeline (Figura 1). Os coeficientes calculados revelaram distâncias extremamente elevadas entre as submatrizes, registrando valores de 0,91 entre o Tópico 2 e o Tópico 3, 0,86 entre o Tópico 2 e o Tópico 1, e picos de isolamento geométrico envolvendo o Tópico 4 e as demais dimensões. Como uma distância de cosseno próxima a 1,0 indica ortogonalidade perfeita no espaço vetorial, esses índices comprovam que a arquitetura NMF proposta por Magotra et al. [5] elimina com sucesso as redundâncias que enfraquecem modelos baseados em LDA, consolidando-se como uma abordagem metodologicamente estável, reproduzível e de alta fidelidade para a auditoria de relatórios de sustentabilidade.




Figure 1: Mapa de Distância Inter-Tópicos via Métrica de Cosseno (NMF).

3.2 Desempenho e Validação Comparativa dos Classificadores Supervisionados

Para responder à segunda questão de pesquisa, avaliou-se a capacidade preditiva de classificadores supervisionados acoplados a uma esteira de vetorização densa baseada em embeddings pré-treinados do Word2Vec. O processo de vetorização customizado (*Word2VecVectorizerPretrained*) operou convertendo os conjuntos de palavras-chave estruturadas em matrizes contínuas por meio da concatenação de suas métricas estatísticas de média, valor máximo e valor mínimo, gerando um espaço de entrada equivalente a três vezes o tamanho original do vetor vetorial ($3 \times \text{dim}$). O desenho do experimento foi submetido a uma estratégia de validação cruzada *k-fold* com cinco partições ($k = 5$), garantindo o embaralhamento dos dados com o uso de uma semente de aleatoriedade fixa (*random_state=42*), assim como no experimento original. A fim de contextualizar a robustez da arquitetura proposta por Magotra et al. [5], conduziu-se uma varredura sistemática testando seis classificadores distintos sob as mesmas condições de contorno. A

Tabela 3 consolida os índices médios de desempenho obtidos ao final do procedimento de validação cruzada.

Os resultados dispostos na Tabela 3 validam empiricamente e com precisão decimal o framework reproduzido. O modelo Random Forest alcançou uma acurácia média de 87,16% (equivalente aos 87,2% reportados na literatura de referência) e um F1-score ponderado de 86,92%. O principal indicador de estabilidade do modelo reside em seu desvio padrão extremamente reduzido ($\sigma = 0,0084$), o que demonstra que o algoritmo de florestas aleatórias é imune a flutuações nas partições dos relatórios industriais. Modelos baseados em comitês de decisão fracos, como AdaBoost (84,81%) e Gradient Boosting (82,10%), mantiveram desempenhos competitivos, porém registraram taxas de variância significativamente superiores à do Random Forest. Em contrapartida, abordagens lineares puras como a Regressão Logística falharam em capturar as nuances não-lineares dos embeddings, performando com acurácia insatisfatória de 61,49%.

Adicionalmente, para auditar a distribuição dos acertos do classificador por categoria alvo, extraiu-se a matriz de confusão sobre o conjunto de teste segregado (Figura 2). O mapeamento revelou um cenário de convergência ideal para a amostra isolada de 60 documentos, computando 24 classificações exatas para a dimensão Environmental, 14 para Governance e 22 para Social. Embora o acerto integral reflita a alta especificidade do dicionário de palavras-chave estruturado pelos autores originais quando processado por vetores densos, a validação cruzada externa ($k = 5$) apresentada na Tabela 3 cumpre o papel de relativizar essa exatidão, demonstrando que o modelo real em produção opera em uma faixa saudável e generalizável de 87,16% de acurácia média.



Figure 2: Matriz de confusão do classificador Random Forest.

3.3 Mapeamento Topológico Discursivo via Grafos de Coocorrência

Para mapear a topologia discursiva subjacente e complementar os achados da decomposição matricial do NMF, o pipeline executou

uma modelagem computacional de grafos não-direcionados por meio da biblioteca NetworkX, aplicando uma função customizada de filtragem estrita onde arestas só seriam estabelecidas caso o par de vocábulos registrasse uma frequência mínima de coocorrência igual a cinco (≥ 5). Os layouts dos grafos foram computados por ordenação de forças através do algoritmo de mola (*spring layout*), vinculando o tamanho dos nós proporcionalmente aos seus respectivos índices de centralidade de grau (*degree centrality*) e a espessura das arestas ao peso das frequências conjuntas. As topologias resultantes para os quatro eixos temáticos encontram-se consolidadas na Figura 3.

A análise estrutural da Rede do Tópico 1 (Segurança Ocupacional) revela um núcleo rígido e indissociável formado pelo par de nós *safety* e *fire*, cuja aresta exibe a maior espessura vetorial do grafo. Este par atua como o principal polo de atração da sub-rede, indexando de forma imediata os nós de alta centralidade *worker*, *facility*, *compliance* e *employee*. Tal configuração demonstra que, na indústria têxtil de Bangladesh, a discussão sobre conformidade regulatória está diretamente atrelada à prevenção de incêndios e segurança das instalações físicas de trabalho.

Na Rede do Tópico 2 (Sustentabilidade Ambiental), o vocábulo *sustainability* emerge como o *hub* estrutural dominante da topologia, apresentando a maior centralidade de grau. Ele ancora de forma simétrica as demandas operacionais de ecoeficiência da cadeia de suprimentos, conectando as arestas de maior peso voltadas a *environmental*, *water*, *reduce*, *energy* e *waste*. Essa distribuição prova que as menções ambientais nos relatórios não são dispersas, mas sim centralizadas em torno de metas claras de redução de consumo de recursos e descarte de resíduos.

A Rede do Tópico 3 (Ações Comunitárias) exibe uma malha discursiva homogênea e altamente integrada, onde os nós *program*, *worker*, *provide*, *school* e *education* compartilham distribuições de centralidade equilibradas, evidenciando o foco das empresas em relatar investimentos em infraestrutura social externa e escolaridade para as famílias dos colaboradores.

Por fim, a Rede do Tópico 4 (Ações de Saúde) desvela uma formação topológica atípica e especializada, caracterizada por componentes fortemente conectados que isolam termos técnicos hospitalares. Destacam-se as conexões densas entre as díades *art* ↔ *pediatric* e a cadeia *burn* ↔ *unit* ↔ *intensive* ↔ *care*. Esse achado revela que a governança social das empresas analisadas frequentemente canaliza investimentos filantrópicos para o financiamento de alas de tratamento médico infantil e unidades especializadas em queimaduras, demonstrando uma aplicação contextualizada e rastreável da responsabilidade social empresarial no território de Bangladesh.

4 Ameaças à Validade

A análise da robustez e da confiabilidade deste experimento de reprodução computacional exige a delimitação de fatores que podem mitigar a generalização ou a estabilidade de seus achados, categorizados sob as dimensões clássicas de validades empíricas.

A principal ameaça à validade interna reside na sensibilidade intrínseca dos algoritmos a pequenas variações nas etapas de preparação e higienização textual. O pipeline original implementa um ecossistema de pré-processamento complexo com remoção agressiva de

Table 3: Matriz Comparativa de Desempenho dos Modelos de Classificação Supervisionada

Classificador Algorítmico	Acurácia Média	F1-Score Ponderado	ROC-AUC Média	Variância (σ) do F1-Score
Regressão Logística	61,49%	56,50%	0,9444	$\pm 0,1230$
k -Nearest Neighbors (k -NN)	75,99%	74,69%	0,9420	$\pm 0,0463$
Árvore de Decisão (<i>Decision Tree</i>)	64,54%	64,19%	0,7261	$\pm 0,0222$
Random Forest (Estudo Original)	87,16%	86,92%	0,9678	$\pm 0,0084$
AdaBoost	84,81%	84,68%	0,9518	$\pm 0,0243$
Gradient Boosting	82,10%	81,72%	0,9469	$\pm 0,0423$




Figure 3: Redes de Coocorrência de Termos para os Quatro Eixos Temáticos ESG

stop words customizadas e lematização seletiva baseada em tags gramaticais via SpaCy. Embora o código de reprodução tenha fixado com sucesso as sementes de aleatoriedade (`random_state=42`) para garantir a convergência idêntica das matrizes do NMF e das árvores do Random Forest, atualizações futuras e silenciosas nas dependências subjacentes das bibliotecas de Processamento de Linguagem Natural podem induzir flutuações marginais nos scores de coerência de tópicos ou nas regras de tokenização.

No escopo da validade externa, o maior limitador concentra-se na natureza homogênea e altamente nichada do dataset avaliado.

O corpus restringe-se estritamente a 82 empresas têxteis sediadas em Bangladesh que já possuem a certificação LEED (Leadership in Energy and Environmental Design). Consequentemente, a capacidade de extrapolar esse framework algorítmico para indústrias têxteis de países com mercados e legislações trabalhistas distintas, ou para fábricas que não passem pelo crivo ambiental do selo LEED, permanece aberta.

5 Conclusões

Este trabalho apresentou uma reprodução computacional parcial e uma auditoria empírica do pipeline de processamento de linguagem natural e aprendizagem de máquina proposto por Magotra et al. [5] para o mapeamento e categorização de divulgações ESG na indústria de vestuário e têxtil de Bangladesh. Por meio da reexecução de seu código sobre o conjunto de dados secundários original das 82 corporações com certificação LEED, o estudo cumpriu com êxito o objetivo de responder às três questões de pesquisa estabelecidas, validando de forma rigorosa as propriedades estatísticas do framework de referência.

Os principais achados deste estudo consolidam-se em dois pilares fundamentais:

- **Superioridade Algébrica:** O algoritmo NMF demonstrou estabilidade semântica substancialmente superior à abordagem probabilística do LDA. Enquanto o LDA registrou um score de coerência insatisfatório de 0,3 e severa sobreposição de palavras-chave estruturais, a fatoração matricial isolou os quatro macrotemas originais com alta especialização e ortogonalidade matemática comprovada por distâncias de cosseno limítrofes a 1,0 e um score de coerência de 0,3756.
- **Resiliência Preditiva:** O classificador supervisionado baseado em Random Forest alimentado por representações densas do Word2Vec validou com precisão decimal a acurácia global de 87,16% sob validação cruzada, provando ser o algoritmo mais apto para mitigar o desequilíbrio nativo do volume de relatórios corporativos se confrontado com modelos lineares ou baseados em boosting.
- **Topologia Rastreável:** A análise de grafos via NetworkX ratificou que as estruturas discursivas das redes de coocorrência orbitam em núcleos topológicos coesos (como as conexões densas entre *safety* e *fire* no Tópico 1) e trouxe à tona investimentos corporativos altamente localizados em infraestrutura social, como o financiamento de alas médicas pediátricas no Tópico 4.

Em suma, conclui-se que o framework desenvolvido por Magotra et al.[5] exibe alta maturidade científica e estabilidade algorítmica, qualificando-se como uma arquitetura auditável e reproduzível para o monitoramento automatizado de compromissos socioambientais em cadeias globais de suprimentos. Como trabalhos futuros, recomenda-se a expansão deste experimento por meio de uma reprodução em sentido estrito, aplicando este mesmo pipeline de PLN e Random Forest sobre relatórios de sustentabilidade emitidos por polos industriais têxteis da América Latina ou do Sudeste Asiático, permitindo traçar um panorama comparativo global das narrativas ESG no setor.

6 Reprodutibilidade e Ciência Aberta

Alinhado com as diretrizes e boas práticas de Ciência Aberta (*Open Science*), todos os dados utilizados neste estudo, tal como o código do experimento e instruções de como executá-lo são disponibilizados de forma pública e gratuita para fins de auditoria, validação e extensão por parte da comunidade científica.

O código-fonte completo do pipeline de processamento de linguagem natural e aprendizado de máquina, bem como o *corpus*

textual estruturado e os dicionários ESG de referência, encontram-se hospedados em um repositório público do GitHub, acessível através do seguinte endereço:

<https://github.com/LS-Flerus/AI-Powered-ESG-Analysis-Replication>

O repositório está licenciado sob a licença de código aberto *MIT License*, permitindo a livre redistribuição, modificação e uso acadêmico ou comercial, desde que mantidos os créditos aos autores originais e desta reprodução.

References

- [1] Christos Boutsidis and Efstratios Gallopoulos. 2008. SVD-based initialization: A head start for nonnegative matrix factorization. *Pattern Recognition* 41, 4 (2008), 1350–1362.
- [2] Julian Eggert and Edgar Körner. 2004. Sparse coding and NMF. In *Proceedings of the 2004 IEEE International Joint Conference on Neural Networks*, Vol. 4. IEEE, 2529–2533.
- [3] International Labour Organization. 2023. The Rana Plaza disaster ten years on: What has changed? InfoStories. Acessado em: 25 mai. 2026. <https://webapps.ilo.org/infostories/en-GB/Stories/Country-Focus/rana-plaza.html>
- [4] Md. Saiful Islam, Md. Abdur Rakib, and Atm Adnan. 2016. Ready-made garments sector of Bangladesh: Its contribution and challenges towards development. *Stud* 5 (2016), 02–12.
- [5] Agraj Magotra, Md. Rafiqul Islam Rana, Shishir, Fairuz Shadmani Shishir, and Sumaiya Shomaji. 2026. A machine learning and NLP pipeline for analyzing ESG and sustainability disclosures in the textile and apparel industry. *Scientific Reports* (apr 2026). doi:10.1038/s41598-026-49931-z
- [6] Aijaz Panhwar, Abdul Sattar Jatoti, Shaukat Ali Mazari, Aftab Kandhro, Uzma Rashid, and Sofia Qaisar. 2024. Water resources contamination and health hazards by textile industry effluent and glance at treatment techniques: A review. *Waste Management Bulletin* 1, 4 (mar 2024), 158–163. doi:10.1016/j.wmb.2023.09.002